

Обучение локальной модели длины изометрий

Дата: 20 сентября 2026. Проект iso_length_train. Документ для устной защиты: что сделали, как устроена модель, как считаются миллиметры, как запустить без Cursor.

1. Задача

По PDF-изометрии трубопровода нужно получить физическую длину трассы в мм. Суммируются только размеры класса include. Не входят координаты X/Y/Z, DN, номера позиций, штурвалы, вложенные отступы опор, габариты Н.О./LT, если участок уже покрыт, и числа из штампа / спецификации / таблицы «Длины отрезков».

Считаем без внешнего API (не Groq, не Gemini, не OpenAI). Текст берётся из PDF через PyMuPDF, решение — локальный CatBoost на GPU, поверх него жёсткие геометрические гарды. Итог листа = сумма include, не ответ модели числом.

2. Что сделали 20.09.2026

- Офлайн CatBoost GPU (NVIDIA RTX 3070, CUDA, device 0). Не ExtraTrees CPU и не облачные LLM.
- Обучение на листах 1–277 файла Изометрии.pdf (джоб output\Изометрии_без_API). Holdout 278–307 = тест_1/2/3 никогда не в train.
- Точность длины даёт не F1, а гарды поверх бустинга: вложенность, Н.О., штурвал, штамп.
- find_nested_parent: только ближайший больший; эталон 916□1950 и 300□840. Прогон 1600 не вкладывается в габарит 3505.
- Немая оболочка ≥3000 поверх прогона с опорой (3505 над 1600) — exclude_nested.
- Н.О.: если цепочка опор не закрывает участок — берём полный размер, куски выкидываем. Лист 8 = 48625 мм (23525+1000+24100).
- Порог abstain 0.9 на валидации оставлял дыры в сумме (coverage ≈ 0.71). В проде classify берёт argmax, без класса «глянуть».
- Restore ложного exclude_nested / not_length: модель часто ставит «не длина» на обычный участок — гард возвращает его в сумму, если нет штурвала/опоры/толщины.
- Лист 9 SW_1009: 123+244+123 на изломе — длина трубы рядом с плашкой «ИЗОЛЯЦИЯ: Н», не толщина. Съёмный участок / отверстия / врезка входят в сумму. Эталон листа 9: 860 мм, не 370.
- Числа из штампа, спецификации материалов и «Длины отрезков» больше не кандидаты: это условие чертежа, не ось.
- output разделён: обучение только Изометрии_без_API; тесты считаются во вкладке Расчёт (джоб 02_Изометрии_10_листов_без_API).

3. Параметры модели (факты из models/training_report.json)

Вид: catboost_gpu_v1. Устройство: GPU 0 (NVIDIA CUDA). Источник данных: Изометрии_без_API. Holdout-проверка: ok=True, листов train=277, пересечение с тестами пустое.

Гиперпараметры CatBoost: depth=5, learning_rate=0.03, l2_leaf_reg=12.0, min_data_in_leaf=20, random_strength=1.2, bagging_temperature=0.7, loss=MultiClass, eval_metric=TotalF1:average=Macro, early_stopping_rounds=100, od_wait=100, iterations (потолок)=1200, use_best_model=true. class_weights: include=1.2, exclude_nested=2.2, not_length=1.8. Плюс sample_weight: locked×8, overall×5, nested_offset×4, handwheel/insulation×3.5, support_repeat×2.5, exclude_nested×2.2, крупные значения ×1.8.

Разбиение: GroupShuffleSplit, n_splits=1, test_size=0.18, random_state=42 (группы = листы, чтобы размеры одного листа не текли в val). best_iteration = 354. Train: 7070 размеров / 227 листов, accuracy=0.959, macro-F1=0.944. Validation: 1639 размеров / 50 листов, accuracy=0.933, macro-F1=0.914. overfit_gap_macro_f1 = 0.031 (порог ok < 0.05, факт overfit_ok=True).

Подбор порога abstain на val (coverage / accuracy_accepted / macro-F1): 0.50 → 0.998 / 0.936 / 0.914; 0.90 → 0.710 / 0.973 / 0.815. В отчёте выбран threshold=0.5. В боевом classify для catboost_gpu_v1 порог не применяется: берётся argmax. Иначе «глянуть» дырявит сумму листа.

Ошибка суммы по листам (до гардов, по меткам модели): train MAE 2397.035242290749 мм, median AE 42.0; val MAE 3966.32 мм. Именно поэтому гарды обязательны.

4. Признаки (local_model.py FEATURE_NAMES)

value, log_value, x, y, big, small, has_z, has_sm, has_dn, has_lt, n_near, has_larger_near, nested_ratio, support_mark, f_overall_mark, f_overall_pair, f_handwheel, f_insulation, f_support_repeat, f_near_plant_coord, f_near_endpoint, f_nested_offset

Числовые: величина и log, координата на листе, флаги «крупный ≥8000» и «мелкий ≤200». Текст рядом: Z+, CM, DN, LT, число соседей, есть ли больший сосед, отношение к нему, метка опоры Op. Флаги extract: H.O., overall_pair, штурвал, близость к плашке изоляции, повтор опоры, координата узла, конец трассы, вложенный отступ. Флаг insulation остаётся признаком модели; в сумму его больше не мапят, если число не внутри самой плашки (insulation_thickness).

5. Классы и где лежит разметка

include — самостоятельный участок или ветка по оси, включая короткие изломы, вертикали, съёмный участок, отверстия, врезку.

exclude_nested — тот же физический кусок уже покрыт (916 в 1950, 300 в 840, LT/overall_pair, полная цепочка vs H.O., немая оболочка 3505).

not_length — координата, DN, позиция, штурвал, толщина изоляции внутри плашки, повтор опоры, штамп, спецификация, «Длины отрезков».

ambiguous — только ручная неуверенность при разметке; в проде CatBoost его не ставит.

Учебный джоб: output\Изометрии_без_API (277 листов). llm_raw\sheet_XX.json — решение по каждому D; overlays*_ids.png — жёлтые D1, D2 на источнике; overlays*_hits.json — координаты (руками не править); markup*.png — цветной результат. Эталон 10 листов — отдельный расчётный джоб, не смешивать с обучением.

6. Как считается длина

1) extract.py, PyMuPDF: целые числа с листа, отсев координат/DN/баллонов/номеров ≤16 и теперь всей правой колонки (спецификация), нижнего штампа и таблицы длин.

2) local_model.classify: CatBoost argmax по вектору признаков.

3) guards.apply_guards: H.O. и цепочка, вложенные опоры, штурвал, restore ложных отказов, немая оболочка, отверстия обратно в сумму.

4) Сумма только decision=include. Формула собирается программно, не моделью.

7. Эталон 10 листов (актуальные мм после правок 20.09)

PDF data\02_Изометрии_10_листов.pdf — обрезанные листы без правой спецификации, удобны как золотой набор. Изменился только лист 9: излом 123+244+123 добавлен. Штурвалы 159 (лист 4) и 244 (лист 10) остаются серыми. Врезка на листе 10 в сумме.

Лист	Линия	Было, мм	Стало, мм	Формула
1	SW_1002	5563	5563	$1383 + 600 + 2160 + 900 + 320 + 200 = 5563$ мм
2	P15_1039	21956	21956	$730 + 174 + 1406 + 1900 + 150 + 1788 + 4072 + 599 + 3626 + 5644 + 1350 + 293 + 224 = 21956$ мм
3	P15_1037	6880	6880	$2364 + 950 + 500 + 1250 + 198 + 224 + 228 + 200 + 168 + 146 + 178 + 210 + 264 = 6880$ мм
4	SW_1003	2772	2772	$250 + 214 + 214 + 504 + 378 + 81 + 171 + 81 + 154 + 190 + 380 + 155 = 2772$ мм
5	LC_1034	8508	8508	$285 + 651 + 850 + 238 + 450 + 2000 + 2400 + 34 + 1600 = 8508$ мм
6	LC_1042	10521	10521	$285 + 651 + 850 + 238 + 2463 + 2000 + 2400 + 34 + 1600 = 10521$ мм
7	LC_1040	4306	4306	$60 + 1950 + 34 + 650 + 840 + 522 + 250 = 4306$ мм
8	SW_1001	48625	48625	$23525 + 1000 + 24100 = 48625$ мм
9	SW_1009	370	860	$195 + 123 + 244 + 123 + 175 = 860$ мм
10	SW_1012	5216	5216	$154 + 341 + 220 + 188 + 134 + 550 + 2450 + 341 + 149 + 220 + 135 + 134 + 200 = 5216$ мм

Лист 9: D1=195 (вертикаль, съёмный участок) + D2=123 + D3=244 + D4=123 (излом у плашки типа) + D5=175 (к ПОДКЛЮЧЕНИЕ) = 860. ШТУРВАЛ UP далеко от 244 (это не штурвал, в отличие от листа 10).

8. Что говорить на защите

- Точность длины = правила геометрии поверх градиентного бустинга, а не F1 классификации.
- Holdout честный: листы 278–307 исходного комплекта ни разу не были в train/val.
- Дообучения в проде нет:.pkl замораживается, Расчёт только inners + гарды.
- API нет: PDF → признаки → CatBoost → гарды → сумма include.
- Модель ошибается на сумме листа (val MAE тысячи мм) — гарды это чинят: Н.О., вложенность, restore.
- Плашка изоляции — тип покрытия, не толщина; соседние размеры на оси — труба.
- Таблица «Длины отрезков» дублирует ось и добавляет DN: если её суммировать, длина раздувается (пример LC_1029: 9336 вместо ~4880).
- Эталон листа 8 (48625) и листа 9 (860) — контрольные кейсы неполного Н.О. и ложной изоляции.

9. Как запустить без Cursor

```
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt
python app.py # http://127.0.0.1:8765 ██████████ ██████████
python -m unittest test_guards -v
██████████_██████████.bat # prepare / annotate / audit / train
```

Модель: models\iso_clf.pkl — не удалять, без неё Расчёт не размечает. Учебные растры output\Изометрии_без_API нужны только чтобы переучить. Пакет для мастера:

output\проверка_мастеру\index.html.

Репозиторий обычный git, не Cursor-hosted. Перед архивом см. docs\перед_архивом.txt.